2 zadanie

Delta Lake

Apache Iceberg

- Ograniczone wspracie w DB
- ACID
- Wersjonowanie danych
- Wspiera wiele executorów
- Wydajne dla malej ilości plikow

Lepsze gdy

- Wiele silnikow analitycznych jest w uzyciu
- Skalowanie danych w petabite'ach
- DataBricks nie jest w uzyciu

3 zadanie

- **Złożoność operacyjna** – wiele warstw to więcej kodu, testów i trudniejsze utrzymanie.
- **Wysoki koszt przetwarzania** – wielokrotne odczyty/zapisy danych zwiększają zużycie zasobów.
- **Opóźnienia w dostępie do danych** – dane muszą przejść przez wiele etapów zanim będą dostępne dla użytkownika końcowego.
- **Dane mogą być zduplikowane** – przechowywanie tej samej informacji w wielu warstwach zwiększa zużycie przestrzeni.
- **Brak elastyczności** – sztywny schemat bronze/silver/gold może nie pasować do wszystkich przypadków użycia.
- **Trudniejsza analiza przyczyn błędów** – problem może wystąpić w jednej z kilku warstw, co utrudnia debugowanie.
- **Wysoka bariera wejścia** – wymaga dobrej znajomości procesu ETL, warstw i zależności między nimi.
- **Powielanie logiki biznesowej** – czasem podobne transformacje są wykonywane na różnych poziomach.
- **Wysoki narzut na testowanie** – każda warstwa musi być osobno testowana, wersjonowana i monitorowana.

- **Niepotrzebna rozbudowa** – dla prostych use case’ów tworzenie wielu warstw to przerost formy nad treścią.
- **Sztuczne granice między warstwami** – niektóre przekształcenia mogłyby być zrobione od razu, bez etapu pośredniego.
- **Problemy z synchronizacją danych** – błędy mogą wystąpić przy niespójności wersji między warstwami.
- **Zwiększone ryzyko błędów ludzkich** – więcej kodu to większa szansa na błędy podczas aktualizacji.
- **Wydłużony czas rozwoju** – budowa każdej warstwy osobno zajmuje więcej czasu projektowego.
- **Trudności z audytem** – przy wielu wersjach danych ciężej zidentyfikować, które były wykorzystane analitycznie.
- **Nieprzyjazne dla eksploracji ad hoc** – dane surowe (bronze) mogą być trudno dostępne bez przejścia przez pipeline.
- **Zła implementacja przynosi chaos** – brak dobrych praktyk może prowadzić do zduplikowanych i niespójnych tabel.
- **Problemy ze zgodnością danych** – zmiana schematu w jednej warstwie może złamać downstream.
- **Trudna automatyzacja** – automatyczne monitorowanie i retry procesów między warstwami może być skomplikowane.
-